

Discrete Data Clustering: Model Based e Distance Based clustering bayesiano a confronto

Tommaso Menghini matricola 864946

Tommaso Pozzi matricola 864654

24 Aprile 2025

Abstract

In questo progetto si sono confrontati due algoritmi per l'analisi di cluster di dati discreti in un contesto bayesiano. In particolare, si è voluto far luce sulle principali differenze tra Model-Based clustering e Distance Based in un contesto non comune. Per effettuare questo confronto si sono utilizzate due tecniche di clustering principali: modelli mistura di multinomiale, attraverso Latent Class Model, e generalized Bayes product partition model, strumento distance based implementato in un contesto generalized Bayes. Per effettuare questo confronto è stato effettuato uno studio di simulazione dove sono stati considerati tre scenari simulativi differenti. Infine, per verificare la veridicità dei metodi proposti si è sviluppata un'applicazione su un sondaggio effettuato dal Dipartimento di Statistica e Scienze Attuariali dell'Università di Stellenbosch sugli effetti dell'alcol nei rendimenti scolastici.

1 Introduzione

Il clustering è una branca della statistica che si occupa di raggruppare le informazioni provenienti dai dati con l'obiettivo di ottenere massima omogeneità all'interno dei gruppi e massima eterogeneità tra di essi. Quando i dati sono numerici, il clustering spesso si basa su misure di distanza come possono essere la distanza euclidea o la distanza di Manhattan. Tecniche note riguardano approcci Distance Based come il k-means e approcci Model Based come la modellizzazione dei cluster attraverso misture di distribuzioni gaussiane. Questi strumenti sono ottimi quando i dati sono numerici, tuttavia, trovano difficoltà nell'ottenere risultati ragionevoli quando questi sono categorici. In molti contesti applicativi, come ricerche di mercato, analisi di testi o fascicoli sanitari, è facile trovare dati di questo tipo. Il clustering di dati categorici mostra diverse sfide: in primis, non è presente una vera e propria misura di distanza riferita a dati di questo tipo. Basti pensare alla distanza euclidea, essa non può essere applicata a dati categorici. In questo progetto si vogliono mettere a confronto due approcci entrambi relativi ad un contesto bayesiano. Il primo approccio può essere definito un approccio Distance Based. La referenza principale è l'articolo Rigon et al. (2023) dove si contestualizza il clustering in un framework generalized Bayes. Il generalized Bayes è un'estensione del classico approccio bayesiano che consente una maggiore flessibilità nell'utilizzo della funzione di perdita e nella valutazione delle credenze soggettive, spesso utile in contesti in cui la specificazione corretta della distribuzione delle osservazioni è difficile o incerta. L'idea chiave è quella che la distribuzione a posteriori venga aggiornata attraverso una funzione di perdita e non più attraverso la verosimiglianza. Questo approccio viene definito *generalized* poichè, se come funzione di perdita si utilizzasse il logaritmo della distribuzione di probabilità dei dati, si otterrebbe l'approccio classico bayesiano. Esso viene confrontato con un approccio Model Based, in particolare, con i Latent Class Model introdotti da Goodman (1974). I Latent Class Model sono dei modelli mistura di distribuzioni multinomiali. Il vantaggio di trovarsi in un contesto bayesiano riguarda sicuramente la stima dell'incertezza. Se in ambito di Model Based, la stima dell'incertezza era possibile anche in ambito classico, per quanto riguarda gli algoritmi Distance Based ciò non era così scontato. Questi ultimi vengono definiti *crispy* proprio perchè forniscono un approccio poco flessibile al clustering. Con l'implementazione del clustering attraverso generalized Bayes si è in grado di fornire una misura dell'incertezza delle partizioni ottenute. Il progetto viene così strutturato: nelle Sezioni 2 e 3 vengono introdotte le nozioni teoriche relative ai due approcci, in Sezione 4 viene svolto uno studio di simulazione al fine di confrontare i due metodi e per concludere uno studio applicativo sui dati reali viene implementato in Sezione 5.

2 Generalized Bayes Product Partition Model per Dati di tipo categorico

In Rigon et al. (2023) si illustra un approccio generalized Bayes per fare clustering. Questo framework fornisce una distribuzione di probabilità che caratterizza l'incertezza del clustering senza però la necessità della specificazione di una verosimiglianza per i dati. L'aggiornamento delle conoscenze a posteriori usando le informazioni provenienti dai dati è condotto attraverso la distribuzione Gibbs posterior. Siano X i dati, c un parametro di interesse e $\pi(c)$ la prior corrispondente. Viene definita come Gibbs posterior la seguente espressione:

$$\pi(c|\lambda, X) \propto \pi(c) \exp \{-\lambda \ell(c; X)\}, \quad (1)$$

con $\lambda > 0$ e $\ell(c; X) \geq 0$ funzione di perdita. La Gibbs posterior produce un aggiornamento delle convinzioni razionale, per questo può essere considerata come una vera e propria distribuzione a posteriori. Inoltre, l'inferenza bayesiana standard è un caso speciale di Equazione 1, ottenuta scegliendo $\lambda \ell(c; X)$ affinché sia una log-verosimiglianza negativa.

Viene introdotta una classe di generalized product partition model (GPPM) con lo scopo di effettuare clustering. Questa famiglia è caratterizzata da una funzione di perdita che ammette la fattorizzazione mostrata in Equazione 2. Per $k = 1, \dots, K$ si considera $X_k = \{x_i : i \in C_k\}$ come l'insieme delle osservazioni appartenenti k-esimo cluster, si definisce la funzione di perdita come:

$$\ell(c; X) = \sum_{k=1}^K \sum_{i \in C_k} D(x_i; X_k), \quad c : |C| = K \quad (2)$$

con $D(x_i, X_k) \geq 0$ misura che quantifica la discrepanza tra l'i-esima unità e il k-esimo cluster.

Sia $\ell(c; X)$ funzione di perdita come mostrato in Equazione 2 e $\pi(c)$ la distribuzione a priori associata alla partizione dei dati c , allora la generalized Bayes posterior sotto un modello generalized Bayes product partition è definita come:

$$\pi(c|\lambda, X) \propto \pi(c) \prod_{k=1}^K \rho(C_k; \lambda, X_k) \propto \prod_{k=1}^K \exp \left\{ -\lambda \sum_{i \in C_k} D(x_i; X_k) \right\}, \quad c : |C| = K. \quad (3)$$

La funzione $\rho(C_k; \lambda, X_k) = \exp \left\{ -\lambda \sum_{i \in C_k} D(x_i; X_k) \right\}$ viene definita cohesion function e rappresenta la compattezza del k-esimo cluster. Nell'approccio generalized Bayes l'obiettivo dell'inferenza è una partizione ottima e sconosciuta c_{OPT} , che può essere stimata dai dati e di cui si è interessati nel quantificare l'incertezza. In tal senso, in Rigon et al. (2023), sono state sviluppate alcune strategie per l'inferenza a posteriori, che non sono le uniche, un esempio sono le palle di credibilità introdotte da Wade and Ghahramani (2018).

Per la stima puntuale una scelta ragionevole è il massimo a posteriori $\hat{c}_{MAP} = \arg \max_c \pi(c|\lambda, X)$ che può essere ottenuto equivalentemente attraverso la minimizzazione della loss function $\ell(c; X)$ sullo spazio delle partizioni con K componenti,

$$\hat{c}_{MAP} = \arg \min_{c: |C|=K} \sum_{k=1}^K \sum_{i \in C_k} D(x_i; X_k).$$

Per ottenere questa stima viene proposto l'algoritmo Bregman k-means, approfondito nella Sezione A.2 dell'Appendice.

Per una stima puntuale alternativa e per la quantificazione dell'incertezza è possibile implementare un Gibbs sampler in grado di campionare dalla distribuzione mostrata in Equazione 3. Siano $c_{-i} = (c_1, \dots, c_{i-1}, c_{i+1}, \dots, c_n)$ le etichette dei cluster senza l'i-esima osservazione e sia $\{C_{1,-i}, \dots, C_{K,-i}\}$ la partizione associata. Nel Gibbs sampler ciclicamente vengono riallocate le etichette c_i campionando dalle full conditionals. È importante che $|C| = K$, cioè che il numero di cluster rimanga fisso e che pertanto non si possa riallocare l'i-esima unità se essa è l'unico elemento in un determinato cluster.

Sia $\pi(c|\lambda, X)$ un modello generalized Bayes product partition, la full conditional di c_i dato c_{-i} è:

$$\Pr(c_i = k | c_{-i}, \lambda, X) \propto \frac{\rho(C_k; \lambda, X_k)}{\rho(C_{k,-i}; \lambda, X_{k,-i})} \quad (4)$$

per ogni partizione c : $|C| = K$. Intuitivamente l' i -esima unità viene allocata nel k -esimo cluster se la cohesion del nuovo cluster $\rho(C_k; \lambda, X_k)$ è maggiore della vecchia $\rho(C_{k,-i}; \lambda, X_{k,-i})$. Il fatto che la generalized Bayes clustering posterior non richieda l'uso di parametri latenti è il maggior vantaggio computazionale sui modelli mistura. Da Equazione 4 è possibile ricavare le probabilità di allocazione a ciascun cluster per nuovi dati, infatti si supponga che sia a disposizione una nuova osservazione x_{n+1} , allora:

$$\Pr(c_{n+1} = k | \lambda, X, x_{n+1}) \propto \frac{\rho(C_{k,n+1}; \lambda, X_{k,n+1})}{\rho(C_k; \lambda, X_k)} \quad k = 1, \dots, K, \quad (5)$$

con $C_{k,n+1}$ e $X_{k,n+1}$ che rappresentano rispettivamente l'insieme degli indici della k -esima componente e la matrice dei dati associata, una volta aggiunta la $(n+1)$ -esima osservazione.

In Rigon et al. (2023) si specializzano questi modelli considerando una famiglia di cohesion functions, basata sulle divergenze di Bregman approfondite in A.1.

Sia $\pi_\varphi(c | \lambda, X)$ un modello generalized Bayes product partition. Si afferma che il modello è descritto da cohesion di Bregman se la distribuzione a posteriori può essere scritta come:

$$\pi_\varphi(c | \lambda, X) \propto \prod_{k=1}^K \rho(C_k; \lambda, X_k) = \prod_{k=1}^K \exp \left\{ -\lambda \sum_{i \in C_k} D_\varphi(x_i; \bar{x}_k) \right\}, \quad c : |C| = K, \quad (6)$$

con $D_\varphi(x_i; \mu)$ che indica una divergenza di Bregman e $\bar{x}_k$ il centroide del cluster.

La divergenza di Bregman valutata in $\bar{x}_k$ non è sempre ben definita perché il centroide non per forza appartiene al supporto delle osservazioni $\mathbb{X}$. Questa problematica si riscontra tipicamente con i dati discreti.

Il contesto che si vuole approfondire è quello di dati categorici; significa che un'osservazione $x_i = (x_{i1}, \dots, x_{id})$ è un vettore di variabili categoriche per cui x_{ij} , con $j = 1, \dots, d$, può assumere m_j possibili livelli. La natura di questi dati comporta i problemi appena citati con la loss function. Si propone allora un modello generalized Bayes caratterizzato da Cross Entropy cohesion con centroidi aggiustati $\tilde{x}_k$. Questa scelta per il modello è il risultato di un'altra connessione fondamentale mostrata nell'articolo Rigon et al. (2023); infatti, sono stati in grado di trovare un nesso logico tra le famiglie di dispersione esponenziale, approfondite nell'Appendice in Sezione A.1, e i modelli generalized Bayes con cohesion di Bregman. Si afferma che un modello generalized Bayes product partition basato sulle famiglie di dispersione esponenziale ha equivalente rappresentazione di una generalized Bayes posterior con le cohesion di Bregman. Una conclusione del genere nella pratica è di grande aiuto in particolare nella scelta della loss function. Nel caso in questione, in presenza di osservazioni di tipo categorico, si può considerare la verosimiglianza di una Multinomiale, da cui è banale osservare la perdita associata: Cross-Entropy. La distribuzione a posteriori proposta è:

$$\pi_\varphi(c | \lambda = 1, X) \propto \prod_{k=1}^K \prod_{i \in C_k} \exp \left\{ \sum_{j=1}^d \sum_{h=1}^{m_j} \mathbf{1}(x_{ij} = h) \log(\tilde{x}_{kjh}) \right\},$$

dove $\tilde{x}_{kjh}$ corrisponde al centroide aggiustato associato al k -esimo cluster per la variabile j -esima e per la categoria h . Nel modello considerato non sono presenti parametri di scala. Seguendo quanto mostrato in Rigon et al. (2023) risulta scelta logica considerare un parametro λ costante e pari a 1.

Nel caso preso in studio ogni centroide è una matrice con un numero di righe pari al numero massimo di classi presente tenendo in considerazione tutto il dataset, e con un numero di colonne pari al numero di covariate. Quindi l'elemento $\tilde{x}_{kjh}$ del centroide è corrispondente alla within-cluster proportion aggiustata della classe h per la covariata j del cluster k .

Come descritto precedentemente, per ragioni legate a problematiche nel comportamento della funzione di perdita, è necessario aggiustare i centroidi, Rigon et al. (2023) ricorre nuovamente alla connessione tra la famiglia di dispersione esponenziale e il modello generalized Bayes con le cohesion di Bregman. Si fa uso di una funzione di penalità per arrivare a stime ben definite. In Firth (1993) si mostra che una scelta conveniente come penalty function per le famiglie di distribuzione esponenziale può essere interpretata come la distribuzione a priori di Jeffreys' associata alla likelihood scelta, aspetto trattato nella Sezione A.2. In questo studio i dati seguono la distribuzione di una Multinomiale a cui è associata una prior di

Jeffreys Dirichlet simmetrica con tutti i parametri uguali a $1/2$. In conclusione i centroidi aggiustati sono:

$$\tilde{x}_{kjh} = \frac{n_{kjh} + \alpha}{n_k + m_j \alpha}$$

dove n_{kjh} indica il numero di osservazioni appartenenti al k -esimo cluster che assumono la categoria h nella variabile j -esima. n_k indica il numero di osservazioni appartenenti al k -esimo cluster, mentre m_j rappresenta il numero di classi associate alla variabile j .

3 Bayesian Latent Class Model

Un secondo approccio per la modellizzazione di dati categorici avviene attraverso Model Based clustering. In particolare vengono sfruttati i modelli mistura di distribuzione multinomiale, o più comunemente noti come Latent Class Model. I Latent Class Model (LCM), introdotti da Lazarsfeld (1950) nel caso binario e successivamente estesi al caso multicategoriale da Goodman (1974) permettono di osservare un approccio model based al clustering di variabili categoriche. Per inquadrare e definire il modello vi è la necessità di descrivere il contesto in cui essi vengono applicati. In particolare, le osservazioni, vengono descritte da d variabili categoriche. Ciascuna di esse ha m_j possibili livelli ($j = 1, \dots, d$) e viene codificata dal vettore x_i^{jh} tale per cui:

$$x_i^{jh} = \begin{cases} 1 & \text{se } x_i^j = h \\ 0 & \text{altrimenti} \end{cases}$$

per $j = 1, \dots, d$ e $h = 1, \dots, m_j$. Il modello è definito dalla seguente distribuzione di probabilità:

$$f(x_i | \alpha, \tau) = \sum_{k=1}^K \tau_k M(x_i | \alpha_g) = \sum_{k=1}^K \tau_k \prod_{j,h} (\alpha_k^{jh})^{x_i^{jh}} \quad (7)$$

dove α_g^{jh} corrisponde alla probabilità che la variabile j assuma livello h quando l'osservazione i -esima appartiene al k -esimo cluster e rappresenta il vettore di probabilità relativo alla distribuzione multinomiale: $\alpha_k = (\alpha_k^{jh}, j = 1, \dots, d; h = 1, \dots, m_j)$. Il vettore $\tau = (\tau_1, \dots, \tau_K)$ rappresenta il vettore delle mixing probabilities delle K componenti del modello mistura ed ha il vincolo tale per cui $\sum_{k=1}^K \tau_k = 1$. Una proprietà fondamentale del modello è l'assunzione di indipendenza condizionata delle variabili osservate, dato il cluster latente di appartenenza. Questa assunzione è nota come indipendenza locale (Lazarsfeld (1968)). In questo progetto viene sviluppata un'estensione bayesiana del modello proposto da Goodman (1974). In particolare, nei modelli mistura bayesiani, è pratica comune utilizzare, quando disponibili, distribuzioni a priori coniugate rispetto alla verosimiglianza completa introducendo in questo modo uno step aggiuntivo che prende il nome di data augmentation. Inoltre, in Frühwirth-Schnatter (2006) si mostra come sia scelta consueta assumere che i parametri del modello α siano indipendenti dalla distribuzione delle mixing probabilities τ . La distribuzione a priori relativa ai parametri del modello può essere quindi espressa nella forma:

$$\pi(\tau, \alpha) = \pi(\tau) \pi(\alpha). \quad (8)$$

Come già anticipato, in questo progetto è proposto un metodo data augmentation per poter simulare dalla distribuzione a posteriori del modello mistura. In particolare, indicate con z_i le variabili latenti del modello, in un contesto bayesiano è necessario imporre una distribuzione a priori anche su di esse. Si considera:

$$z_i | \tau \sim Multinom(1; \tau_1, \dots, \tau_K) \quad (9)$$

dove i parametri $\tau_1, \dots, \tau_K$, vettore delle mixing probabilities, viene anche considerato come vettore di iperparametri relativo alla distribuzione a priori della variabile latente z . Sarà proprio il vettore delle variabili latenti z a determinare le partizioni a posteriori ottenute attraverso Gibbs-Sampling. Trattando i pesi del modello mistura come iperparametri della distribuzione delle allocazioni latenti, ed essendo questa distribuita come una Multinomiale, viene naturale associare come prior la distribuzione coniugata *Dirichlet*($b_1, \dots, b_K$). Resta da definire la distribuzione a priori relativa ai parametri della distribuzione

Multinomiale del modello. Anche in questo caso è scelta banale sfruttare la coniugatezza della distribuzione *Dirichlet* ed imporre a priori:

$$(\alpha_k^{j1}, \dots, \alpha_k^{jm_j}) \sim \text{Dirichlet}(c_1, \dots, c_K), \quad (10)$$

per $k = 1, \dots, K$ e $j = 1, \dots, d$.

La simulazione dalla distribuzione a posteriori dei parametri del modello avviene attraverso Gibbs-Sampling, come più dettagliatamente descritto in Appendice Sezione A.3.

Da tenere in considerazione è il fatto che nei modelli mistura è sempre importante distinguere tra componenti e cluster. Le componenti della mistura rappresentano le distribuzioni latenti che compongono il modello. Il modello assume che i dati osservati siano generati da una combinazione di queste componenti secondo una distribuzione a priori sui pesi. I cluster, invece, rappresentano i gruppi nei quali le osservazioni vengono assegnate in base alla probabilità a posteriori di appartenenza alle componenti. In un contesto di clustering basato su modelli, come in questo caso, una data osservazione viene assegnata al cluster corrispondente alla componente con la probabilità a posteriori più elevata. Tuttavia, l'associazione tra componenti e cluster non sempre è univoca: in alcuni casi, più componenti possono modellare lo stesso cluster, mentre in altri una singola componente può contenere cluster distinti.

4 Studio di simulazione

Per verificare la veridicità dei due metodi e per effettuare un confronto oggettivo tra Model Based clustering (Sezione 3) e Distance Based clustering (Sezione 2) si è deciso di svolgere uno studio di simulazione. In particolare, è stato condotto considerando 3 approcci differenti, descritti approfonditamente nelle Sezioni 4.1, 4.2, 4.3. Le partizioni ottime sono state ricavate in tutti e tre gli esempi attraverso un approccio decisionale. In particolare, la stima della partizione ottima si è ottenuta minimizzando le funzioni di perdita Binder simmetrica (Binder (1978)) (A.6) e Variation of Information (Meilă (2007)) (A.5). Questo approccio viene utilizzato per risolvere il cosiddetto problema del Label-Switch. Le due funzioni di perdita utilizzate differiscono per forma e struttura. La prima, Binder simmetrica, si occupa principalmente di osservare quando due osservazioni che sarebbero dovute appartenere allo stesso cluster, vengono assegnate a due cluster differenti e, quando vengono clusterizzate assieme, ma provengono da due cluster diversi. La VI è una funzione di perdita costruita a partire dalla teoria dell'informazione e compara l'informazione presente in due raggruppamenti con l'informazione condivisa tra essi. Formalmente essa viene definita in termini di entropia. L'entropia nel clustering è una misura d'incertezza e viene utilizzata principalmente per valutare la purezza di una partizione. I primi ad utilizzare la Variation of Information come approccio decisione per la stima della partizione ottima sono stati Wade and Ghahramani (2018). Anche in questo lavoro si utilizza un approccio simile andando a minimizzare un limite inferiore rispetto alla vera funzione di perdita. Per maggiore dettagli si rimanda all'Appendice A.5. La bontà del clustering ottenuto attraverso la partizione ottima è stata valutata attraverso l'Adjusted Rand Index (Rand (1971)) (descritto in A.7). L' Adjusted Rand Index è una misura compresa tra -1 ed 1 in grado di dare una valutazione oggettiva della bontà del nostro raggruppamento quando i veri cluster sono noti. Questa misura è utile specialmente in un contesto simulativo poiché è nota la vera partizione con cui sono stati generati i dati. In un contesto applicativo, l'ARI risulta invece una misura insoddisfacente. Valori di ARI vicino ad uno indicano una partizione molto simile a quella reale con cui sono stati generati i dati, un valore vicino a zero indica che le partizioni sono state generate dal caso; valori negativi indicano partizioni più dissimili di quanto previsto dal caso. Fuori da un contesto simulativo, non esiste una vera e propria definizione di cluster corretti o veri cluster, dato che questa dipende dall'obiettivo e dal contesto in cui si effettua il clustering. Di conseguenza, non esiste una soluzione unica per il loro ottenimento, ma diversi obiettivi possono portare a diverse soluzioni. L'utilizzo di approcci Model Based o Distance Based può dipendere molto dal tipo di dati e dalla loro struttura.

I dati per l'analisi sono stati simulati seguendo il metodo proposto in Linzer and Lewis (2011). Un punto chiave dello studio di simulazione è come vengono generati i dati. Se si indica con α_k^{jh} come la probabilità che la j -esima variabile assuma categoria h nel k -esimo cluster, essa può essere strutturata in questo modo (proposto da Biernacki et al. (2010)):

$$\alpha_k^{jh} = \begin{cases} \frac{1}{m_j} + (1 - \delta) \frac{m_j - 1}{m_j} & \text{se } h = [(k - 1) \bmod m_j] + 1 \\ \frac{(1 - \frac{1}{m_j} - (1 - \delta) \frac{m_j - 1}{m_j})}{m_j - 1} & \text{altrimenti.} \end{cases} \quad (11)$$

Il parametro $0 \leq \delta \leq 1$ è la componente esogena del modello e permette di definire la sovrapposizione all'interno dei cluster. Valori di δ vicini ad uno indicano un forte overlap, valori di δ vicini a zero un overlap minimo. Per una visualizzazione esemplificativa della sovrapposizione tra i cluster si rimanda a Sezione A.8 dell'Appendice. In questo studio di simulazione sono stati comparati diversi valori del parametro δ per verificare come i due algoritmi si comportassero al variare del grado di sovrapposizione dei dati. I Gibbs sono stati stimati con un numero di iterazioni pari a 10000 e un periodo di burn in di 2000. La convergenza è stata valutata sull'entropia per entrambi i metodi e anche sulla loss function prodotta ad ogni iterazione per quanto riguarda il generalized Bayes product partition (GBPP).

4.1 Studio di simulazione I

In questo primo studio di simulazione sono stati campionati 4 dataset composti relativamente da 200, 400, 600 e 800 osservazioni per testare l'andamento del modello all'aumentare della numerosità campionaria. I dati generati sono sempre composti da 6 variabili rispettivamente articolate da 3 livelli per le prime 4 variabile del dataset e 4 livelli per le ultime due. Il parametro δ esplicitato alla sezione precedente è stato fatto variare tra 0.25, in modo da garantire minimo overlap e cluster ben distinti; 0.4 tale per cui l'overlap tra i dati fosse mediocre e 0.6 in modo da strutturare un forte overlap. I dati sono stati simulati supponendo l'esistenza di due classi latenti sbilanciate, una con proporzione pari a 0.3, mentre l'altra con proporzione pari a 0.7. In Tabella 1 sono riportati i risultati ottenuti. Da questo primo studio di simulazione è possibile concludere che, se i dati sono poco complessi, ben separati e con un numero di osservazioni relativamente basso entrambi i modelli sono ottimi. D'altra parte quando la struttura tra i dati diventa più complessa, il modello LCM risulta più stabile e computazionalmente meno complesso.

N	Generalized Bayes Product Partition				Latent Class Model			
	ARI_VI	ARI_Binder	Overlap	Time (Min)	ARI_VI	ARI_Binder	Overlap	Time (Min)
200	0.9788	1.0000	25%	7.94475	0.9788	0.9788	25%	16.68461
400	0.9795	0.9795	25%	33.74457	0.9795	0.9795	25%	33.06845
600	0.9795	0.9795	25%	77.93862	0.9727	0.9727	25%	49.55873
800	0.9797	0.9797	25%	133.75524	0.9898	0.9898	25%	66.68334
200	0.8255	0.8255	40%	8.43471	0.9007	0.9007	40%	16.65518
400	0.8252	0.8252	40%	32.58051	0.8906	0.8619	40%	36.69812
600	0.8122	0.8121	40%	75.50766	0.8676	0.8419	40%	59.55849
800	0.8714	0.8620	40%	127.53211	0.9048	0.8807	40%	66.16026
200	0.4687	0.3664	60%	7.20997	0.7430	0.7406	60%	19.41362
400	0.4140	0.3645	60%	27.74410	0.5105	0.4704	60%	36.98565
600	0.4204	0.3580	60%	62.81808	0.7014	0.5902	60%	49.58179
800	0.5715	0.4774	60%	96.49812	0.7016	0.6151	60%	67.88762

Tabella 1: Risultati simulazione I

Come evidente, quando si considera un overlap minimo, entrambi i modelli stimano delle partizioni che rispecchiano i "veri" cluster ottenuti. È possibile affermare che quando i dati sono ben separati entrambi i modelli sono in grado di stimare le corrette partizioni dei dati. I modelli in condizione di scarso overlap portano livello di ARI molto vicini ad uno, anche all'aumentare della numerosità campionaria. Il tempo computazionale, come previsto, aumenta all'aumentare di N. Tuttavia, nel modello mistura il tempo computazionale sembra essere più contenuto per numerosità campionarie elevate. I valori di ARI sono molto simili sia per la funzione di perdita Binder che per la funzione VI e questo indica che entrambe le metodologie di sintetizzazione della distribuzione a posteriori delle partizioni sono in grado di catturare la qualità del clustering in modo coerente nel contesto sperimentale. Aggiungendo overlap ai dati si osserva

come il modello Latent Class sia più robusto in condizioni di alta sovrapposizione. Si osserva, infatti, come il valore di ARI cala da 0.87-0.82 per il modello GBPP (ottenuto in caso di media sovrapposizione) a circa 0.42-0.5 in caso di elevata sovrapposizione. Nei Latent Class model si nota un divario meno netto dove, in caso di elevato overlap tra i dati, per N pari a 200, si raggiunge addirittura un ARI pari a 0.74. Nel caso di elevato overlap, la funzione di perdita Binder simmetrica porta a stime della partizione ottima che produce valori di ARI inferiori rispetto alla Variation of Information. Ciò non avveniva nel caso di overlap minori.

4.2 Studio di simulazione II

Per il secondo studio di simulazione si è deciso di complicare le ipotesi da cui vengono generati i dati. In particolare, l'obiettivo è quello di osservare come i due modelli si comportano in caso di variabili con un numero elevato di possibili categorie. In particolare, i dati sono stati generati, ancora, composti da 6 variabili, tuttavia ora le variabili possono assumere, rispettivamente, 3,15,10,3,13 e 4 possibili livelli. Inoltre si sono predisposte tre classi latenti, con probabilità pari a 0.2, 0.5 e 0.3. I risultati di questo nuovo studio di simulazione sono espressi in Tabella 2.

Generalized Bayes Product Partition					Latent Class Model			
N	ARI_VI	ARI_Binder	Overlap	Time (Min)	ARI_VI	ARI_Binder	Overlap	Time (Min)
200	1.0000	1.0000	0.25	9.72930	1.0000	1.0000	0.25	25.28540
400	0.9876	0.9876	0.25	43.08137	0.9950	0.9950	0.25	54.49408
600	0.7756	0.4752	0.25	83.15791	0.9902	0.9902	0.25	73.96621
800	0.7563	0.4726	0.25	142.59414	0.9852	0.9852	0.25	103.7994
200	0.8678	0.8573	0.40	11.075881	0.8943	0.8978	0.40	28.69338
400	0.8684	0.8759	0.40	38.172469	0.8933	0.9008	0.40	50.58157
600	0.9305	0.9214	0.40	80.77758	0.9428	0.9318	0.40	75.18121
800	0.8720	0.8390	0.40	136.13011	0.8717	0.8352	0.40	101.26381
200	0.5706	0.5439	0.60	9.008632	0.6083	0.5541	0.60	25.98323
400	0.4811	0.4388	0.60	35.01083	0.5978	0.5453	0.60	50.75723
600	0.5538	0.4906	0.60	67.53798	0.6421	0.5903	0.60	71.68141
800	0.5956	0.5554	0.60	116.58282	0.7186	0.6208	0.60	98.57343

Tabella 2: Risultati simulazione II

Anche in questo caso si osserva come dati con un basso livello di sovrapposizione vengono partizionati quasi perfettamente per N relativamente piccoli. Con l'aumentare della numerosità campionaria, il modello Generalized Bayes fatica a trovare le corrette partizioni con cui sono suddivisi i dati, mentre il Latent Class Model continua a proporre partizioni che comportano elevati valori della metrica considerata. I tempi computazionali sono simili a quelli osservati nella sezione precedente per quanto riguarda il modello proposto da Rigon et al. (2023), mentre per il modello LCM si è verificato un notevole incremento. Questo può essere dovuto alla struttura del Gibbs-Sampling da cui viene campionata la distribuzione a posteriori che è sensibile a incrementi dal numero di livelli. Infatti, per ogni iterazione del gibbs-sampler, la complessità della distribuzione del vettore α è proporzionale al numero di livelli di ciascuna variabile. Inoltre, l'algoritmo di simulazione MCMC relativo al modello LCM aumenta il numero di cicli che deve svolgere all'aumentare del numero di cluster, dato che il vettore $(\alpha_k^{j_1}, \dots, \alpha_k^{j_{m_j}})$ dipende da k . Il modello GBPP sembra comportarsi in maniera migliore rispetto a quanto evidenziato in Sezione 4.1 in questo nuovo contesto. Questo può essere dato dal fatto che, aumentando il numero di livelli per variabile, le distanze tra i vari cluster e le osservazioni diventano più significative e l'algoritmo è in grado di riconoscerle meglio. Inoltre, considerando soltanto 2 gruppi è possibile che l'algoritmo riconoscesse punti simili tra loro, ma appartenenti a cluster differenti e li inserisse all'interno della stessa partizione. Aumentando il livello delle variabili si aumenta l'eterogeneità presente nei dati e si aumenta la differenziazione tra le osservazioni. In questo modo si riduce l'incertezza e ciò ha un effetto sulle partizioni trovate. Anche in questo esempio simulativo, entrambe le metriche, Binder e VI sembrano portare a valori di Adjusted Rand Index coerenti. Nel caso dei Latent Class Models, le partizioni ottime ottenute attraverso VI sembrano essere più coerenti con i veri cluster rispetto a quelle ottenute con la funzione di perdita Binder

simmetrica quando l'overlap è forte. Anche con questo nuovo scenario simulativo, il modello LCM sembra essere migliore quando i dati sono sovrapposti. In conclusione è possibile affermare che il modello mistura è in grado di ottenere partizioni che rispecchiano i veri valori dei gruppi quando la sovrapposizione tra le osservazioni è abbastanza elevata, mentre i due metodi si equivalgono quando i dati sono ben separati. Utilizzare questi metodi quando il numero dei livelli per ciascuna variabile è alto è ottimale poichè, come si è verificato, questi funzionano meglio per i motivi descritti precedentemente.

4.3 Studio di simulazione III

Nei due scenari simulativi precedenti, per quanto concerne il modello descritto in Sezione 2, si è utilizzata una prior uniforme sulle partizioni, ossia:

$$\pi(c) = \frac{1}{S(n, K)} \propto 1, \quad c : |C| = K. \quad (12)$$

In questo nuovo scenario simulativo, si vuole utilizzare una distribuzione sulle partizioni Multinomial-Dirichlet e osservare come ciò impatti sulla stima puntuale. In particolare, si vuole mostrare come gli iperparametri ad essa associati impattino sulla stima ottima dei cluster. La prior può essere scritta nella forma:

$$\pi(c) \propto \frac{\Gamma(\sum_{k=1}^K \beta_k)}{\Gamma(\sum_{k=1}^K \beta_k + n)} \prod_{k=1}^K \frac{\Gamma(\beta_k + n_k)}{\Gamma(\beta_k)}. \quad (13)$$

Questa nuova specificazione della distribuzione a priori, come mostrato in A.4, porta ad una full-conditional per il modello GBMM del tipo:

$$P(S_i = k | -) \propto \frac{\Gamma(\beta_k + n_{k(-i)} + 1)}{\Gamma(\beta_k + n_{k(-i)})} \times \frac{\exp(-\ell(\{X_l : S_l = k\} \cup \{X_i\}))}{\exp(-\ell(\{X_l : S_{-i} = k\}))} \quad (14)$$

In questo nuovo scenario simulativo si è considerata la situazione mostrata in Sezione 4.1. In particolare, ci si è concentrati sui casi in cui i modelli proposti incontravano difficoltà nell'effettuare il clustering, valutando se l'introduzione di nuove informazioni a priori potesse contribuire a migliorare i risultati ottenuti. Lo scenario simulativo è il seguente: si considerano due classi latenti con probabilità rispettivamente pari a 0.3 e 0.7. I dati vengono generati con un grado di sovrapposizione pari al 65% e un numero di osservazioni pari a 200. Il dataset è sempre composto da 6 variabili, ciascuna rispettivamente di 3, 3, 3, 3, 4 e 4 livelli. I risultati di questo terzo studio simulativo sono espressi in Tabella 3.

	ARI_VI	ARI.binder	Time (min)
Prior Uniforme	0.3888	0.3425	6.3983
beta = (10, 10)	0.6663	0.7168	6.1269
beta = (5, 15)	0.6973	0.6393	6.3049
beta = (100, 1)	0.4953	0.4953	5.2863
beta = (3, 7)	0.6816	0.6626	5.1485
Empirical Bayes (c = 10)	0.6251	0.6236	5.2927
Latent Class Model	0.6365	0.5697	17.5369
K-Bregman	0.1261	0.1261	0.0015

Tabella 3: Risultati simulazione III

Come già esplicitato precedentemente, in questa sezione si sono valutati diversi valori dei parametri β associati alla distribuzione Multinomial-Dirichlet con lo scopo di giudicare la performance dell'algoritmo di clustering proposto in Sezione 2. Il nuovo contesto viene inoltre confrontato con il precedente, ossia con modello GBMM con prior uniforme, con il Latent Class Model bayesiano e con l'algoritmo adjusted K-Means di Bregaman, descritto in Sezione A.2 dell'Appendice. I risultati sono coerenti con le aspettative. Quando l'informazione sulla distribuzione delle classi latenti è nota, ossia nei casi in cui si è imposto un valore di β pari a (3, 7) e (5, 15), il modello funziona molto bene e riesce a migliorare la sua performance rispetto al caso uniforme di circa il 44%. Al contrario, prior non informative o non coerenti con la struttura

latente dei dati, come un beta pari a $\beta = (1, 100)$, ossia con un' impostazione a priori completamente sbilanciata verso una classe, conducono a performance nettamente inferiori. Un ultimo approccio provato è considerato parecchio controverso nella comunità bayesiana dato che utilizza i dati per elicitarre gli iperparametri della distribuzione a priori. In questo caso si sono considerati i risultati del cluster ottenuto attraverso l'algoritmo di Bregman. Di queste si sono prese le frequenze relative associate a ciascun cluster e moltiplicate per un parametro di concentrazione $\mathbf{c}$. $\mathbf{c}$ è il nuovo iperparametro del modello. Di questo risultato moltiplicativo si è considerata soltanto la parte intera. Si può osservare come questo approccio fornisca dei risultati ottimi e molto simili al risultato ottenuto attraverso il modello LCM. Questo può essere considerato un approccio da tenere in considerazione quando non si hanno particolari informazioni a priori sulla distribuzione dei dati.

5 Applicazione

L'applicazione dei modelli generalized Bayes viene svolta su un dataset pubblicato sulla piattaforma Kaggle dal Dipartimento di Statistica e Scienze Attuariali dell'Università di Stellenbosch. Si tratta di un sondaggio condotto su studenti composto da varie domande di carattere personale e accademico. L'obiettivo dello studio è quello di identificare dei cluster di studenti con pattern interpretabili. Inoltre si vuole fornire la probabilità di assegnazione a ciascun cluster nel caso in cui si conducesse il sondaggio su un nuovo studente.

Il dataset comprende 16 covariate e 295 osservazioni, da cui vengono rimosse 3 osservazioni come set su cui valutare la probabilità di appartenenza a ciascun cluster. Le domande, ovvero le covariate, hanno risposta multipla; pertanto, applicare il modello generalized Bayes per dati di tipo categorico descritto in sezione 2 è una scelta ragionevole. Per determinare il numero di cluster K viene utilizzata la stima puntuale $\hat{c}_{MAP}$ per un certo range di valori di K , ottenuta attraverso l'algoritmo Bregman k-means aggiustato, approfondito in Sezione A.2 dell'Appendice. Quindi si è calcolata la sequenza di loss minimizzate, ognuna associata a un valore di K . Questa sequenza è decrescente rispetto a K . L'applicazione della regola del gomito suggerisce un numero di cluster tra due e quattro. Si sono scelti 3 cluster. L'analisi è stata condotta in prima battuta con una prior uniforme sui cluster della partizione, poi ripetuta utilizzando la prior Dirichlet-Multinomial, descritta in Equazione 13 con il parametro β basato sulle frequenze dei cluster associate a $\hat{c}_{MAP}$. Questa seconda tipologia di prior è utile se si vuole assumere a priori che i cluster della partizione siano diversi in termini di ampiezza.




Figura 1

Il clustering viene stimato attraverso un Gibbs sampler di 15000 iterazioni, dove le prime 5000 sono scartate come burn-in. Si ottiene la stima puntuale $\hat{c}_{VI}$, che minimizza la posterior Variance-Of-Information loss. In Figura 1 si mostrano tre grafici che chiariscono l'interpretazione dei cluster ottenuti considerando

la stima puntuale $\hat{c}_{VI}$. Nel grafico (a) in Figura 1 vengono riportate le proporzioni delle risposte alla domanda *"A quante feste partecipi in una settimana?"* da parte degli studenti dell'università associate alla partizione individuata da $\hat{c}_{VI}$.

Nel terzo cluster sono raggruppate la maggior parte degli studenti che esce *"Zero"* volte o *"Solo weekend"* nella settimana. Il primo cluster, invece, presenta studenti eterogenei per il numero di volte che escono durante la settimana, mentre nel secondo cluster vengono raggruppati tutti quegli studenti che hanno dichiarato di uscire *"Quattro o più"* volte a settimana. Dal grafico (b) di Figura 1 si nota che nel terzo cluster vengono compresi praticamente tutti quegli studenti che hanno risposto alla domanda *"Quando esci quanti drink bevi?"* di non consumare alcol quando escono di casa o che al più consumano *"Da 1 a tre"* drink. Nel secondo cluster, invece, vengono raggruppati circa l'80% di quegli studenti che hanno dichiarato di consumare *"Più di otto"* drink quando escono. Infine, il primo cluster presenta studenti che fanno uso in modo moderato di alcolici. Il grafico (c) di Figura 1 rappresenta la proporzione di appartenenza a ciascun cluster rispetto al valore della media degli esami di uno studente. Si può notare come il cluster 1 sia presente fino al valore *"B+"* per la covariata *"Livello_{GPA}"*, questo indica come la proporzione degli studenti con miglior performance accademiche sia sbilanciata verso il primo cluster. Al contrario, si nota come la proporzione di appartenenza al cluster 2 se si ha una media pari a *C+* o *C* sia maggiore del 50%.

	Cluster I	Cluster II	Cluster III
Student I	0.02	0.00	0.98
Student II	0.07	0.91	0.02
Student III	0.00	0.01	0.99

Tabella 4: Probabilità di allocazione di ciascuno studente ai tre cluster

Un altro obiettivo dell'inferenza a posteriori è quello di calcolare le probabilità di allocazione associate a un nuovo studente. A tal fine si sono rimosse dal dataset tre osservazioni. Utilizzando la formula in Equazione 5 si ottiene il risultato mostrato in Tabella 4, per cui, ad esempio, consistentemente con quanto detto, viene riportato che la probabilità di allocazione al cluster tre dello studente III che ha dichiarato di uscire *"Solo Weekend"*, di consumare *"Da 1 a 3"* drink quando esce e di avere una media degli esami pari a *"C+"* è circa del 0.99.

6 Conclusioni

I Latent Class Models e i generalized Bayes product partition models si sono dimostrati essere eccellenti strumenti per il clustering di dati discreti. I metodi si equivalgono quando la vera partizione sottostante ai dati è composta da gruppi ben separati, mentre il primo risulta più efficiente quando la sovrapposizione delle osservazioni è piuttosto elevata. Inoltre, entrambi funzionano bene anche quando il numero di classi per covariata aumenta. Per quanto riguarda la scelta della distribuzione a priori sui cluster, si mostra nella simulazione che la prior Dirichlet-multinomial migliora nettamente le performance quando è presente il problema di sovrapposizione tra i diversi gruppi della vera partizione dei dati. Nell'applicazione, invece, questo aspetto non viene catturato, in quanto i dati si dimostrano abbastanza informativi da rendere la scelta della prior indifferente. Sempre nell'applicazione si mostra l'efficacia del modello generalized Bayes product partition nello stimare l'incertezza dei cluster e la sua capacità di fornire una spiegazione facilmente interpretabile. Una nota dolente di questi due algoritmi riguarda la complessità computazionale. All'aumentare della numerosità campionaria i tempi computazionali sono veramente elevati e questo è un fattore da tenere in considerazione.

Riferimenti bibliografici

- Mergu S. Dhillon I. S. Banerjee, A. and J. Gosh. Clustering with bregman divergences. *Journal of Machine Learning Research*, 2005.
- Christophe Biernacki, Gilles Celeux, and Gérard Govaert. Exact and monte carlo calculations of integrated likelihoods for the latent class model. *Journal of Statistical Planning and Inference*, 140(11):2991–3002, 2010.
- David A Binder. Bayesian cluster analysis. *Biometrika*, 65(1):31–38, 1978.
- D. B. Dahl and M. A. Newton. Multiple hypothesis testing by clustering treatment effects. *Journal of the American Statistical Association*, page 517–526, 2007.
- D. Firth. Bias reduction of maximum likelihood estimates. *Biometrika*, 1993.
- Sylvia Frühwirth-Schnatter. *Finite mixture and Markov switching models*. Springer, 2006.
- Leo A Goodman. Exploratory latent structure analysis using both identifiable and unidentifiable models. *Biometrika*, 61(2):215–231, 1974.
- Paul Felix Lazarsfeld. Latent structure analysis. 1968.
- PF Lazarsfeld. The interpretation and mathematical foundation of latent class structure analysis. *Measurement and Prediction*, 1950.
- Drew A. Linzer and Jeffrey B. Lewis. poLCA: An R package for polytomous variable latent class analysis. *Journal of Statistical Software*, 42(10):1–29, 2011. URL <https://www.jstatsoft.org/v42/i10/>.
- Marina Meilă. Comparing clusterings—an information based distance. *Journal of multivariate analysis*, 98(5):873–895, 2007.
- William M Rand. Objective criteria for the evaluation of clustering methods. *Journal of the American Statistical association*, 66(336):846–850, 1971.
- T. Rigon, A. Herring, and D. B. Dunson. A generalized bayes framework for probabilistic clustering. *Biometrika*, 2023.
- Sara Wade and Zoubin Ghahramani. Bayesian cluster analysis: Point estimation and credible balls (with discussion). 2018.

A Appendice A

A.1 Divergenza di Bregman e Famiglie di Dispersione Esponenziale

Definizione. Sia $\varphi : \mathbb{X} \rightarrow \mathbb{R}$ una funzione strettamente convessa definita su un insieme convesso $\mathbb{X} \subseteq \mathbb{R}^d$ tale che φ sia differenziabile sull'interno relativo di $\mathbb{X}$. Una divergenza di Bregman è definita come $D_\varphi(x; \mu) = \varphi(x) - \{\varphi(\mu) + (x - \mu)^T \nabla \varphi(\mu)\}$ per ogni $x \in \mathbb{X}$ ed ogni μ nell'interno relativo di $\mathbb{X}$, con $\nabla \varphi(\mu)$ che rappresenta il gradiente del vettore φ valutato in μ .

La divergenza di Bregman $D_\varphi(x; \mu)$ è una quantità non negativa ed è interpretabile come la differenza fra $\varphi(x)$ e il valore dell'iperpiano tangente in μ valutato in x .

Definizione. Sia $\pi(x|\lambda)$ una funzione di densità su $\mathbb{X} \subseteq \mathbb{R}^d$, indicizzata da $\lambda > 0$, e sia Π_λ la sua misura di probabilità. La classe di densità $\pi_{ED}(x|\theta, \lambda) = \pi(x|\lambda) \exp\{\lambda(\theta^T x - \kappa(\theta))\}$, per $\theta \in \Theta$ e $\lambda \in \Lambda$, è una famiglia di dispersione esponenziale, dove $\Theta \times \Lambda = \{(\theta, \lambda) \in \mathbb{R}^d \times \mathbb{R}_+^{n0} : \int_{\mathbb{X}} \exp(\lambda \theta^T x) \Pi_\lambda(dx) < \infty\}$.

Teorema. Sia $\pi_{ED}(c|\lambda, X)$ un modello generalized Bayes product partition della forma

$$\pi_{ED}(c|\lambda, X) \propto \prod_{k=1}^K \prod_{i \in C_k} \pi_{ED}(x_i|\hat{\theta}_k, \lambda) \propto \prod_{k=1}^K \prod_{i \in C_k} \pi(x_i|\lambda) \exp\{\lambda(\hat{\theta}_k^T x_i - \kappa(\hat{\theta}_k))\}$$

per $c : |C| = K$, dove ogni $\hat{\theta}_k = \theta(\bar{x}_k) = \arg \max_{\theta} \prod_{i \in C_k} \pi_{ED}(x_i|\theta, \lambda)$ è la stima di massima verosimiglianza per θ_k per ogni partizione c . Allora esiste un modello generalized Bayes con la cohesione di Bregman come in espressione 6 tale che $\pi_{ED}(x_i|\theta, \lambda) = \pi_\varphi(c|\lambda, X)$, con $c : |C| = K$, per una funzione φ idonea.

A.2 Bregman k-means

Algoritmo 1. Bregman k-means Banerjee and Gosh (2005)

Scegliere K e inizializzare i centroidi $m_1, \dots, m_K$;

Finché la funzione di perdita non cambia $\ell(c; X)$:

Per $i = 1$ a n

Porre l'etichetta c_i pari a k , in modo che $D_\varphi(x_i, m_k)$ è minimo;

Per $k = 1$ a K

Porre m_k uguale al centroide $\bar{x}_k$ del gruppo k ;

Output $\hat{c}_{MAP} = (c_1, \dots, c_n)$.

Come spiegato nella Sezione 2 sorgono alcune difficoltà nella procedura di clustering utilizzando le divergenze di Bregman se il centroide $\bar{x}_k$ non appartiene al supporto delle osservazioni $\mathbb{X}$. Come menzionato, questo problema si incontra tipicamente quando si ha a che fare con dati con supporto discreto, come nel caso preso in studio. Il Teorema mostrato in A.1 suggerisce un aggiustamento. Ogni $\theta(\bar{x}_k)$ può essere rimpiazzato da $\tilde{\theta}_k$, una stima di massima verosimiglianza penalizzata in modo che $\tilde{\theta}_k = \arg \max_{\theta} \pi(\theta|\lambda) \prod_{i \in C_k} \pi_{ED}(x_i|\theta, \lambda)$, per $k = 1, \dots, K$ per una funzione di penalizzazione $\pi(\theta|\lambda)$ che porti a stime ben definite. Equivalentemente si possono rimpiazzare i $\bar{x}_k$ con centroidi aggiustati $\tilde{x}_k = \mu(\tilde{\theta}_k)$, tale che $\tilde{\theta}_k = \theta(\tilde{x}_k)$. In questo caso si ha a che fare con famiglie di dispersione esponenziale, allora la funzione di penalizzazione, scelta come consigliato in Firth (1993) può essere interpretata come la distribuzione a priori di Jeffreys' associata a $\pi_{ED}(x|\theta, \lambda)$. Con questa correzione l'espressione in 6 diventa

$$\pi_\varphi(c|\lambda, X) \propto \prod_{k=1}^K \prod_{i \in C_k} \pi_{ED}(x_i|\theta(\tilde{x}_k), \lambda) \propto \prod_{k=1}^K \exp\{-\lambda \sum_{i \in C_k} D_\varphi(x_i; \tilde{x}_k)\},$$

per $c : |C| = K$. La stima $\hat{c}_{MAP}$ può essere ottenuta attraverso il seguente algoritmo aggiustato.

Algoritmo 2. Bregman k-means Aggiustato Rigon et al. (2023)

Scegliere K e inizializzare i centroidi $m_1, \dots, m_K$;

Finché la funzione di perdita non cambia $\ell(c; X)$:

Per $i = 1$ a n

Porre l'etichetta c_i pari a k , in modo che $D_\varphi(x_i, m_k)$ è minimo;

Per $k = 1$ a K

Porre m_k uguale al centroide aggiustato $\tilde{x}_k$ del gruppo k ;

Output $\hat{c}_{\text{MAP}} = (c_1, \dots, c_n)$.

A.3 Simulazioni dalla posteriori dei Latent Class Model attraverso algoritmi MCMC

Sfruttando il metodo data augmentation e grazie alla coniugatezza della distribuzione Dirichlet nei confronti della distribuzione multinomiale risulta scelta logica campionare dalla distribuzione a posteriori del modello mistura attraverso un Gibbs-Sampling. Le relative full-conditionals sono infatti molto semplici da ricavare. Considerando un numero K di componenti del modello noto, è possibile riscrivere il modello secondo la seguente struttura gerarchica:

$$\tau \sim \text{Dirichlet}(b_1, \dots, b_K) \quad (15)$$

$$z_i | \tau \sim \text{Multinom}(1; \tau_1, \dots, \tau_K) \quad (16)$$

$$(\alpha_k^{j1}, \dots, \alpha_k^{jm_j}) \sim \text{Dirichlet}(c_1, \dots, c_K) \quad (17)$$

$$x_i | z_i, \tau, \alpha_k \sim \text{Multinom}(x_i | \alpha_k), \quad (18)$$

da cui si ricavano le seguenti full-conditionals:

$$\begin{aligned} \tau | - &\sim \text{Dirichlet}(b_1 + n_1, \dots, b_K + n_K) \\ z_i | - &\sim \text{Multinom} \left(1; \frac{\tau_1 \prod_{j=1}^d \prod_{h=1}^{m_j} \alpha_1^{x_i^{jh}}}{\sum_{k=1}^K \tau_k \prod_{j=1}^d \prod_{h=1}^{m_j} \alpha_k^{x_i^{jh}}}, \dots, \frac{\tau_K \prod_{j=1}^d \prod_{h=1}^{m_j} \alpha_K^{x_i^{jh}}}{\sum_{k=1}^K \tau_k \prod_{j=1}^d \prod_{h=1}^{m_j} \alpha_k^{x_i^{jh}}} \right) \\ (\alpha_k^{j1}, \dots, \alpha_k^{jm_j}) | - &\sim \text{Dirichlet} \left(c_1 + \sum_{i=1}^n z_{i1} x_i^{j1}, \dots, c_K + \sum_{i=1}^n z_{iK} x_i^{jK} \right) \end{aligned}$$

dove $n_k = \sum_{i=1}^n \mathbf{1}(z_i = k)$ e $z_{ik} = \mathbf{1}(z_i = k)$

Dimostrazione. Dimostrazione per la full-conditional di τ :

$$\pi(\tau | z) \propto \prod_{k=1}^K \tau_k^{b_k-1} \times \prod_{k=1}^K \tau_k^{n_k} = \prod_{k=1}^K \tau_k^{b_k+n_k-1} \quad (19)$$

Dimostrazione per la full-conditional di z_i :

$$\Pr(z_i = k | x_i, \tau, \alpha) \propto \Pr(z_i = k | \tau) \mathcal{L}(x_i | z_i = k, \tau, \alpha) = \tau_k \prod_{j,h} \alpha_k^{x_i^{jh}} = \omega_k \quad (20)$$

Dimostrazione per la full-conditional di $(\alpha_k^{j1}, \dots, \alpha_k^{jm_j})$:

$$\pi(\alpha_k^{j1}, \dots, \alpha_k^{jm_j} | x, z_k, \tau_k) \propto \pi(\alpha_k^{j1}, \dots, \alpha_k^{jm_j}) \mathcal{L}_c(x | z_k, \tau_k, \alpha_k^j, \tau_k) \propto \quad (21)$$

$$\propto \prod_{h=1}^{m_j} (\alpha_k^{jh})^{c-1} \times \prod_{i=1}^n \prod_{h=1}^{m_j} (\alpha_k^{jh})^{x_i^{jh} z_{ik}} = \quad (22)$$

$$= \prod_{h=1}^{m_j} (\alpha_k^{jh})^{c-1} \times \prod_{h=1}^{m_j} (\alpha_k^{jh})^{\sum_{i=1}^n x_i^{jh} z_{ik}} = \quad (23)$$

$$= \prod_{h=1}^{m_j} (\alpha_k^{jh})^{c-1} \times \prod_{h=1}^{m_j} (\alpha_k^{jh})^{u_k^{jh}} = \prod_{h=1}^{m_j} (\alpha_k^{jh})^{c+u_k^{jh}-1} \quad (24)$$

□

A.4 Dimostrazione full-conditional per modello GBPP con prior Multinomial Dirichlet

Dimostrazione. Si considera $\mathcal{L}(\mathcal{S})$ come la legge delle partizioni e $\mathcal{L}(S, Y)$ come la legge delle partizioni congiunta con i dati. Si definisce invece con $\mathcal{L}(S_i | S_{-i})$ la legge condizionata della partizione dell'osservazione i -esima, date le partizioni di tutte le altre osservazioni. Per il teorema di Bayes essa corrisponde a:

$$\mathcal{L}(S_i | S_{-i}) = \frac{\mathcal{L}(S_i, S_{-i})}{\mathcal{L}(S_{-i})} = \frac{\Gamma(\sum_{k=1}^K \alpha_k)}{\Gamma(\sum_{k=1}^K \alpha_k + n)} \prod_{k=1}^K \frac{\Gamma(\alpha_k + n_k)}{\Gamma(\alpha_k)} \times \frac{\Gamma(\sum_{k=1}^K \alpha_k + n - 1)}{\Gamma(\sum_{k=1}^K \alpha_k)} \prod_{k=1}^K \frac{\Gamma(\alpha_k)}{\Gamma(\alpha_k + n_{k(-i)})}$$

□

Si osserva inoltre che:

$$\mathcal{L}(Y, S) = \mathcal{L}(Y | S) \mathcal{L}(S) = \prod_{k=1}^K \prod_{i: S_i=k} \exp\left(-\sum_{k=1}^K \ell(\{X_i : S_i = k\})\right) \times \frac{\Gamma(\sum_{k=1}^K \alpha_k)}{\Gamma(\sum_{k=1}^K \alpha_k + n)} \prod_{k=1}^K \frac{\Gamma(\alpha_k + n_k)}{\Gamma(\alpha_k)}$$

Unendo queste due equazioni è semplice mostrare che la relativa full-conditionals è pari a:

$$P(S_i = k | -) \propto \frac{\Gamma(\alpha_k + n_{k(-i)} + 1)}{\Gamma(\alpha_k + n_{k(-i)})} \times \frac{\exp(\ell(\{X_l : S_l = k\} \cup \{X_i\}))}{\exp(\ell(\{X_l : S_{-i} = k\}))}$$

A.5 Variation of Information

La VI è costruita partendo dalla teoria dell'informazione e compara l'informazione in due raggruppamenti con l'informazione condivisa tra di essi. Formalmente è definita come:

$$\begin{aligned} VI(\mathbf{c}, \hat{\mathbf{c}}) &= H(\mathbf{c}) + H(\hat{\mathbf{c}}) - 2I(\mathbf{c}, \hat{\mathbf{c}}) \\ &= -\sum_{i=1}^{k_N} \frac{n_{i+}}{N} \log\left(\frac{n_{i+}}{N}\right) - \sum_{j=1}^{\hat{k}_N} \frac{n_{+j}}{N} \log\left(\frac{n_{+j}}{N}\right) - 2 \sum_{i=1}^{k_N} \sum_{j=1}^{\hat{k}_N} \frac{n_{ij}}{N} \log\left(\frac{n_{ij}N}{n_{i+}n_{+j}}\right), \end{aligned}$$

I primi due termini misurano l'entropia calcolata sulle due partizioni (vera e stimata), che esprime la complessità nel prevedere in quale cluster appartiene un'unità statistica selezionata casualmente, conoscendone il partizionamento. Il terzo termine, invece, rappresenta la quantità di informazione condivisa tra le due partizioni che riduce l'incertezza nell'allocare una certa unità in un certo cluster di una partizione $\mathbf{c}$ nel momento in cui è nota la sua assegnazione sotto $\hat{\mathbf{c}}$. Poiché $H(\mathbf{c})$ è costante quando si minimizza per $\hat{\mathbf{c}}$, Wade and Ghahramani (2018) fa notare che la partizione ottima, cioè quella che minimizza la perdita VI attesa a posteriori, è la stessa che determina il minimo della seguente espressione:

$$\begin{aligned}
\hat{\mathbf{c}}^* &= \underset{\hat{\mathbf{c}}}{\operatorname{argmin}} \mathbb{E}[VI(\mathbf{c}, \hat{\mathbf{c}})|\mathcal{D}] \\
&= \underset{\hat{\mathbf{c}}}{\operatorname{argmin}} \sum_{n=1}^N \log \left(\sum_{n'=1}^N \mathbf{1}(\hat{c}_n = \hat{c}'_{n'}) \right) - 2 \sum_{n=1}^N \mathbb{E} \left[\log \left(\sum_{n'=1}^N \mathbf{1}(c_{n'} = c_n, \hat{c}_{n'} = \hat{c}_n) \right) | \mathcal{D} \right]. \quad (25)
\end{aligned}$$

A.6 Binder loss

Per ogni possibile coppia di osservazioni, la funzione di perdita *Binder* penalizza due tipologie di errori:

1. L'assegnazione di due osservazioni a due cluster diversi quando avrebbero dovuto far parte dello stesso;
2. L'assegnazione di due osservazioni allo stesso cluster quando avrebbero dovuto far parte di due diversi;

$$B(\mathbf{c}, \hat{\mathbf{c}}) = \sum_{n < n'} (a \cdot \mathbf{1}\{c_n = c_{n'}\} \mathbf{1}\{\hat{c}_n \neq \hat{c}_{n'}\} + b \cdot \mathbf{1}\{c_n \neq c_{n'}\} \mathbf{1}\{\hat{c}_n = \hat{c}_{n'}\}),$$

con $a > 0$ e $b > 0$ che sono il costo per unità di compiere un errore di miss classificazione.

In Wade and Ghahramani (2018) viene introdotta una versione invariante rispetto ad N , dimensione campionaria, sotto l'assunzione che $a = b = 1$,

$$B(\mathbf{c}, \hat{\mathbf{c}}) = \sum_{i=1}^{k_N} \left(\frac{n_{i+}}{N} \right)^2 + \sum_{j=1}^{\hat{k}_N} \left(\frac{n_{+j}}{N} \right)^2 - 2 \sum_{i=1}^{k_N} \sum_{j=1}^{\hat{k}_N} \left(\frac{n_{ij}}{N} \right)^2, \quad (26)$$

con $n_{i+} = \sum_j n_{ij}$ e $n_{+j} = \sum_i n_{ij}$. Questa espressione è invariante rispetto a N in quanto dipende dalla dimensione del campione solo tramite le proporzioni n_{ij}/N . In Dahl and Newton (2007) viene proposto il criterio dei minimi quadrati per cercare la partizione che minimizza $f(\hat{\mathbf{c}}) = \sum_{n=1}^N \sum_{n'=1}^N (A(\hat{\mathbf{c}})_{nn'} - \hat{\pi}_{nn'})^2$, con $A(\hat{\mathbf{c}})$ matrice $N \times N$ che ha come elemento (nn') $\mathbf{1}\{\hat{c}_n = \hat{c}'_{n'}\}$ e $\hat{\pi}_{nn'}$ stima Monte Carlo della *posterior similarity matrix*, una matrice $N \times N$ che ha come elemento (nn') la probabilità a posteriori che l'osservazione n e n' siano clusterizzate insieme. In Dahl and Newton (2007) si dimostra che minimizzare il criterio sopra è equivalente a minimizzare la stima Monte Carlo della perdita attesa Binder a posteriori con $a = b$. Questo significa che la partizione $\mathbf{c}^*$ ottimale per l'Equazione 26 è quella che minimizza

$$\sum_{n < n'} (\mathbf{1}(c_n = c_{n'}) - \pi_{nn'})^2.$$

A.7 Adjusted Rand Index

L'Adjusted Rand Index è una misura della bontà dei cluster ottenuti quando i veri cluster dei dati sono noti e la sua formulazione è la seguente:

$$\text{ARI} = \frac{\sum_{ij} \binom{n_{ij}}{2} - \left[\sum_i \binom{a_i}{2} \sum_j \binom{b_j}{2} \right] / \binom{n}{2}}{\frac{1}{2} \left[\sum_i \binom{a_i}{2} + \sum_j \binom{b_j}{2} \right] - \left[\sum_i \binom{a_i}{2} \sum_j \binom{b_j}{2} \right] / \binom{n}{2}}, \quad (27)$$

dove:

- n : numero totale di elementi,
- n_{ij} : numero di elementi comuni al cluster i della partizione vera e al cluster j della partizione predetta,
- $a_i = \sum_j n_{ij}$: numero di elementi nel cluster i della partizione vera,
- $b_j = \sum_i n_{ij}$: numero di elementi nel cluster j della partizione predetta.

A.8 Grafici rappresentativi delle differenze per i valori di delta utilizzati nella simulazione

In Figura 2 viene rappresentata una sintesi dei dati generati durante la simulazione effettuata in Sezione 4.2 per delta pari rispettivamente a 0.25 e 0.6. La rappresentazione avviene attraverso l'analisi in corrispondenze multiple ed è esplicativa nello spiegare la sovrapposizione dei dati generati. In particolare vengono rappresentate le prime due componenti.




Figura 2: Differenze nella sovrapposizione dei dati per delta pari a 0.25 e 0.6

A.9 Materiale Supplementare per la Sezione 5

In questa sezione si riportano analisi aggiuntive del dataset studiato nell'applicazione in Sezione 5 del documento principale. Come detto è stato implementato un modello generalized Bayes per dati multica-tegoriali e si è ottenuta la stima puntuale $\hat{c}_{MAP}$ per diversi valori di K attraverso l'algoritmo Bregman k-means aggiustato. Viene scelto $K = 3$.




Figura 3: Loss minimizzate associate a ciascun $\hat{c}_{MAP}$ per $k = 1, \dots, 8$.

In tabella 4 viene associata una probabilità di allocazione al secondo cluster per lo Studente II di 0.91. Quest'ultimo ha dichiarato di uscire "Zero" volte a settimana, di consumare "Più di 5" drink quando

esce, di perdere "2" lezioni a settimana e di avere una media degli esami pari a "B-". Immaginando che questo ragazzo ("Sesso" = "Male") cambi stile di vita nella maniera seguente:

- Esca "Una" volta a settimana;
- Riduca il consumo di alcolici a "Da 1 a 3" drink quando esce;
- Non perda lezioni durante la settimana;
- Migliori la sua GPA a "B+";

allora calcolando nuovamente la sua probabilità di allocazione a ciascun cluster i risultati sarebbero quelli in Tabella 5. Avrebbe quindi una probabilità pari a 0.93 di essere associato al cluster 1.

	Cluster I	Cluster II	Cluster III
Student III	0.93	0.02	0.05

Tabella 5: Probabilità di allocazione dello studente III con il nuovo stile di vita ai tre cluster

Ora vengono ripetute le analisi in Sezione 5, considerando non più una prior uniforme sui cluster, ma bensì una Dirichlet-multinomial prior. Questa tipologia di prior è utile se si vuole assumere a priori che i cluster abbiano dimensioni diverse. Si è posto $\beta = (4, 4, 3)$ e è stato fatto girare il Gibbs sampler per 15000 iterazioni scartando le prime 5000 come burn-in. Si ottiene quindi la stima puntuale $\hat{c}_{VI}$ e in Figura 4 si mostrano gli stessi grafici proposti per l'analisi con prior uniforme. In questo caso




Figura 4

nel grafico (a) di Figura 4 si nota che vengono raggruppati nel primo cluster circa l'80% di quelli che hanno dichiarato di uscire "Zero" volte a settimana e la metà di quelli che hanno risposto di uscire "Solo weekend". Nel secondo cluster sono invece allocati tutti quegli studenti che escono "Quattro o più" volte a settimana. Non solo, infatti in questo cluster sono presenti anche circa la metà di quegli studenti che escono "Due" e "Tre" volte a settimana. Infine nel terzo cluster sono raggruppati studenti eterogenei da questo punto di vista. Il grafico (b) della figura invece mostra che nel primo cluster sono allocati il 93% di studenti che hanno dichiarato di non bere nulla quando escono, ma anche più della metà di quelli che hanno risposto di consumare "Da 1 a 3" e "Da 3 a 5" drink. Il secondo cluster invece è caratterizzato da quegli studenti che secondo il sondaggio consumano "Più di 8" drink quando escono, infatti il 75% di loro viene allocato in questo cluster. Infine il terzo cluster è composto dal 50% circa di quegli studenti

che hanno dichiarato di consumare "Da 5 a 8" drink. Nel grafico (c) si mostrano per ogni livello di media disponibile le proporzioni di appartenenza a ciascun cluster. Si nota come la proporzione degli studenti allocati nel primo cluster che hanno una media pari o più elevata del "B+" è superiore al 50%. Questa proporzione diminuisce con il diminuire della media, fino ad arrivare a nessuno studente allocato nel cluster uno, con una media pari a "C". Se il cluster due sembra invece essere eterogeneo da questo punto di vista, il cluster tre è l'opposto rispetto al primo. Infatti si vede come la proporzione di studenti allocati nel terzo cluster diminuisce all'aumentare della media fino a "A-".

	Cluster I	Cluster II	Cluster III
Student I	0.07	0.00	0.93
Student II	0.09	0.90	0.01
Student III	0.06	0.03	0.90

Tabella 6: Probabilità di allocazione di ciascuno studente ai tre cluster

In Tabella 6 si mostrano le probabilità di allocazione degli stessi studenti considerati in tabella 4, chiaramente considerando la prior alternativa Dirichlet-multinomial. I risultati sono in linea con l'analisi fatta con la prior uniforme.




Figura 5: Probabilità di co-clustering per il modello Cross Entropy generalized Bayes applicato al dataset di sezione 5, sotto diverse specificazioni a priori. Il grafico di sinistra corrisponde al modello con la Dirichlet-multinomial prior, mentre il grafico di destra corrisponde al modello con la prior uniforme

Nel clustering per rappresentare l'incertezza non si possono considerare le probabilità $\text{pr}(c_i = k|\lambda, X)$ perché sono affette dal label-switching. Per questa ragione ci si concentra sulla matrice di co-clustering S il cui elemento $s(i, i') = \text{pr}(c_i = c_{i'}|\lambda, X)$ per $i, i' \in \{1, \dots, n\}$. Ognuna di queste probabilità si può approssimare con un campione MCMC. In figura 5 si mostra la matrice co-clustering sotto la Dirichlet-multinomial prior e sotto la prior uniforme. In entrambi i casi la stima puntuale considerata è la $\hat{c}_{VI}$. Non si nota un impatto da parte del cambio di prior nelle probabilità a posteriori di co-clustering, quindi si conclude che i dati in questo caso sono abbastanza informativi tale per cui l'effetto della distribuzione a priori è indifferente.